

Proyecto Final

Descripción

Este proyecto tiene como propósito integrar los conocimientos adquiridos durante el curso mediante el desarrollo de una aplicación inteligente basada en agentes, que utilice técnicas avanzadas de procesamiento de lenguaje natural, modelos de lenguaje grandes (LLMs) de última generación, sintonización fina (fine-tuning), recuperación aumentada con generación (RAG) de tipo agentic, embeddings, orquestación multiagente bajo protocolos abiertos de interoperabilidad (MCP y A2A) y un componente alto de innovación y/o investigación aplicada en un contexto de aplicación en pleno desarrollo del NLP.

Cada equipo diseñará e implementará una aplicación avanzada basada en un agente autónomo conversacional y posiblemente otros agentes (sistema multiagente), el cual brindará servicios avanzados en múltiples dominios: generación, razonamiento, conocimiento, soporte, guía o entrenamiento a usuarios en un contexto específico (ver más abajo contextos posibles). El agente debe interactuar de forma fluida, buscar y usar herramientas de forma autónoma (tool use), razonar con base en datos externos, mantener memoria de contexto y adaptar sus respuestas al perfil del usuario.

Objetivos del Proyecto

- Diseñar e implementar un agente conversacional basado en LLMs con capacidades avanzadas de interacción, búsqueda de información y razonamiento.
- Integrar técnicas de RAG para enriquecer las respuestas del agente usando fuentes de conocimiento externas.
- Aplicar embeddings, clasificación y análisis de texto como parte de las capacidades del agente.
- Utilizar datasets públicos para entrenar, afinar, evaluar o enriquecer el comportamiento del agente.
- El agente debe incorporar mecanismos de aprendizaje continuo (aprender de la interacción) y soportar comunicación entre agentes mediante estándares abiertos de interoperabilidad, principalmente MCP (Model Context Protocol) y, cuando aplique, A2A (Agent-to-Agent).
- Incluir datos y acciones No estructuradas y Estructuradas.
- Construir una interfaz de usuario funcional (chatbot web o móvil) que demuestre la aplicación.
- Evaluar el impacto y desempeño del agente en un escenario real o simulado.

Etapas propuestas para el Proyecto Final

1. Propuesta del agente y escenario: Definición del caso de uso, justificación del problema a resolver, público objetivo, fuentes de datos y conocimiento, y lo más importante el componente de innovación o investigación aplicada.
2. Diseño de arquitectura: Diagrama de componentes, flujo de interacción del agente, integración con herramientas externas, herramientas utilizadas.
3. Capacidades del agente: Uso de LLM, integración de RAG, embeddings, agentes con herramientas y planificación de tareas, otras capacidades.

4. Desarrollo de la aplicación: Interfaz conversacional, backend orquestador, gestión de contexto y personalización.
5. Evaluación: Estrategia de evaluación del desempeño del agente, pruebas con usuarios o simulaciones.
6. Informe final: Documento técnico con el desarrollo completo, decisiones técnicas, evaluación y propuestas de mejora.

Posibles tecnologías a emplear:

- LangGraph, CrewAI, Claude Agent SDK, OpenAI Agents SDK o Google ADK como framework/SDK de orquestación de agentes
- LLMs de frontera vía API (familias Claude, GPT, Gemini) y modelos open-weight recientes (Llama 4, Qwen3.5, DeepSeek-V3.2, Mistral) desplegados vía Hugging Face u Ollama
- Qdrant, Chroma, Weaviate, Pinecone o pgvector como base de datos vectorial (vector store)
- Streamlit, Gradio, Chainlit o Next.js (Vercel AI SDK) como interfaz web
- Deployment: Hugging Face Spaces, Vercel, Modal, Lightning AI, o notebooks públicos de Colab
- Ecosistema AWS: Bedrock (incluye AgentCore para runtime y orquestación de agentes), OpenSearch (búsqueda vectorial), SageMaker, S3, Lambda, etc. Se puede explorar otros ambientes de nube como Google GCP o Microsoft Azure
- Observabilidad y evaluación de agentes: Langfuse, LangSmith, Arize u otras plataformas de trazabilidad y evaluación de agentes en producción.
- Protocolos de interoperabilidad: MCP (Model Context Protocol) para la conexión con herramientas y fuentes de datos, y A2A (Agent-to-Agent) para la comunicación entre agentes de distintos proveedores.

Proceso para sistemas RAG:

- Carga y preprocesamiento de documentos (PDF, Markdown, HTML o texto sin formato)
- Generación de embeddings y almacenamiento en la base de datos vectorial
- preguntas de los usuarios en lenguaje natural
- Recuperar fragmentos relevantes desde el vector store, aplicando búsqueda híbrida y/o re-ranking cuando aplique
- Utilizar LLM para generar respuestas basadas en el contenido recuperado (RAG agentic: el agente decide cuándo y qué recuperar)
- Mostrar fuentes o evidencia (citación) de la información utilizada.

Innovación y/o investigación aplicada:

Todos los proyectos deben incorporar un componente avanzado exploratorio de futuro del NLP. Cada equipo debe explorar tecnologías emergentes y enfoques experimentales del NLP que, aunque hoy tengan limitaciones prácticas, podrían transformarse en soluciones de alto impacto en un horizonte de 1–5 años. El objetivo es fomentar la investigación, creatividad y pensamiento prospectivo, más que la obtención de resultados determinísticos hoy en día.

Ejemplos de posibles líneas de trabajo:

- NLP Multimodal y Multisensorial: agentes que integren texto, voz, imagen y señales fisiológicas para comunicación más natural.
- Aprendizaje continuo/autónomo (*lifelong learning*): sistemas que aprendan de interacciones prolongadas sin reentrenar desde cero.
- Razonamiento de alto nivel y agentes cognitivos: integración de LLMs con motores de razonamiento simbólico, simulaciones y planificación a largo plazo.
- Comunicación inter-agente compleja: ecosistemas de múltiples agentes especializados que se coordinen de manera autónoma.
- Procesamiento de lenguaje en entornos inmersivos (realidad aumentada/virtual) para educación, entrenamiento o entretenimiento.
- Modelos de lenguaje bio-inspirados: exploración de arquitecturas inspiradas en procesos cognitivos o neurobiológicos.
- Sistemas Multi-agente
- Entrada de datos por voz: (text-to-speech), Generación de voz (TTS), speech-to-speech
- Generación de información diferente a texto (imagenes, videos, etc)
- Visualización avanzada de información (documentos, imagenes, video, sonido, etc)
- Interoperabilidad de agentes: ecosistemas de agentes basados en protocolos abiertos (MCP, A2A) que permiten a agentes de distintos proveedores descubrirse, delegar tareas y colaborar entre sí.
- Observabilidad, evaluación y gobernanza de agentes autónomos: trazabilidad, detección de fallos, mecanismos de control (guardrails) y evaluación continua del comportamiento de agentes en producción.

Contextos de aplicación del Proyecto Final

1. Agente educativo: Público objetivo: estudiantes de primaria, secundaria o universidad. Funciones: explicación de conceptos, generación de quices, resumen de textos, tutor personalizado. Dataset sugeridos: SQuAD, CommonLit, HotpotQA, textos educativos.

En este contexto es requerido sistemas Q&A por ejemplo de materiales de clase o cursos (por ejemplo, libros de texto, diapositivas de conferencias, notas de clase). El sistema utilizará RAG: los documentos se almacenarán en una base de datos vectorial, y un modelo de lenguaje generará respuestas basadas en el contenido recuperado.

2. Agente de entrenamiento deportivo: Público objetivo: deportistas amateurs o avanzados en ciclismo, running, triatlón, etc. Funciones: planificación de entrenamiento, análisis de rendimiento, consejos de nutrición. Dataset sugerido: Strava, bases públicas de fisiología.
3. Broker de negociación: crear agentes que actúen en nombre de un humano para interactuar en sistemas de Bolsa de Valores o ambientes de compra / venta de acciones, o similar.
4. Agente de atención al cliente en cualquier dominio de atención que pase el test de Turing.
5. Opción libre: Propuesta del equipo (finanzas, acciones-bolsa de valores, salud mental, coaching, asistencia legal, etc.), previa validación con los profesores.

Entregables y Cronograma

Semana	Entregable
1	Propuesta del proyecto (1 página) que incluye el componente de innovación y/o investigación avanzada.
2	Diseño de arquitectura del agente y componentes inteligentes de backend.
3	Definición de tecnología de Desarrollo Prototipo funcional inicial
4	Prototipo funcional final
5	Evaluación con usuarios / pruebas Entrega final + demo + informe

Rúbrica de Evaluación

Esta rúbrica será utilizada para evaluar los proyectos finales del curso. Cada criterio será calificado en una escala de 1 a 5, donde 1 representa un nivel insuficiente y 5 un nivel sobresaliente. La nota final será ponderada según los pesos asignados a cada criterio.

Criterios de Evaluación

Criterio	Descripción	Peso (%)
Originalidad e innovación	Nivel de creatividad y novedad en el diseño del agente y su aplicación. Componente de futuro del NLP	15
Calidad técnica	Correcta implementación de técnicas de NLP, LLMs, RAG, embeddings y otros componentes vistos en clase.	25
Uso adecuado de tecnologías	Aprovechamiento efectivo de frameworks como LangChain, OpenAI, HuggingFace, etc.	15
Funcionalidad de la aplicación	Funcionamiento completo y correcto del agente, incluyendo la interfaz.	20
Evaluación y validación	Calidad de las pruebas realizadas y análisis del desempeño del sistema.	10
Presentación final	Claridad, organización y calidad de la presentación oral y/o demo del proyecto.	10
Informe escrito	Calidad del informe técnico entregado, claridad de redacción, profundidad del análisis.	5

Escala de Calificación

- 5 - Sobresaliente: Excede ampliamente las expectativas del criterio.
- 4 - Bueno: Cumple plenamente con las expectativas del criterio.
- 3 - Aceptable: Cumple parcialmente con las expectativas del criterio.
- 2 - Deficiente: Cumple de manera limitada con el criterio.
- 1 - Insuficiente: No cumple con las expectativas del criterio.