

Vallis Marea: De Agente Monolítico a Ecosistema de Agentes Interoperables (MCP/A2A)

1. Caso de uso y justificación del problema

Vallis Marea es un chatbot conversacional multimodal en producción para un negocio de alquiler de lanchas en Cartagena. Corre en AWS EC2 (Ubuntu, dockerizado), con Caddy como reverse proxy TLS, Chatwoot como bandeja unificada que recibe WhatsApp vía Meta Cloud API y dispara webhooks a n8n, Postgres con pgvector y Redis para las colas de Chatwoot. El agente ya recibe texto, voz e imágenes y responde con texto, imágenes o PDFs: n8n clasifica el mensaje, usa Gemini para transcribir audio o describir imágenes, y genera una respuesta JSON estructurada publicada de vuelta en Chatwoot.

A pesar de esta capacidad multimodal ya resuelta, el sistema es un agente monolítico: un único nodo de IA en n8n concentra clasificación, conocimiento, disponibilidad y recomendación, sin separación de responsabilidades ni comunicación formal entre capacidades. Esto limita la escalabilidad y la trazabilidad a medida que crece el negocio. Se propone migrar esta infraestructura hacia un ecosistema de agentes especializados que colaboran mediante protocolos abiertos de interoperabilidad (MCP y A2A).

2. Público objetivo

- **Primario:** turistas y clientes que rentan lanchas en Cartagena vía WhatsApp, atendidos a través de Chatwoot, con expectativa de respuesta inmediata en texto, voz o imagen.
- **Secundario:** el equipo operativo, que usa Chatwoot como consola de supervisión humana y se beneficia de reducir la carga de consultas repetitivas.

3. Arquitectura propuesta (resumen)

Se conserva la capa de infraestructura actual (Caddy, Chatwoot, Meta Cloud API, Postgres/Redis) y se descompone el nodo único de IA en n8n en agentes especializados:

- **Agente Conversador/Orquestador:** recibe el mensaje ya clasificado por modalidad, mantiene memoria y delega cada solicitud al agente correspondiente.
- **Agente de Disponibilidad y Reservas:** servidor MCP que expone herramientas para consultar y bloquear inventario en tiempo real (Sheets/Postgres).
- **Agente de Conocimiento (RAG agentic):** nuevo pipeline sobre pgvector que indexará políticas, FAQs y rutas turísticas, citando la fuente recuperada.
- **Agente Recomendador:** sugiere paseos/embarcaciones según preferencias expresadas por el cliente.

Cada agente conserva el contrato de salida JSON ya validado en producción, ahora orquestado entre agentes vía A2A antes de publicar la respuesta en Chatwoot.

4. Fuentes de datos y conocimiento

- **Estructurados:** inventario, precios y disponibilidad (Sheets → Postgres); historial de conversaciones multimodal indexado.
- **No estructurados:** políticas de cancelación, FAQs y descripciones de rutas turísticas de Cartagena, a indexar en pgvector como parte del nuevo pipeline de RAG.
- **Datos de interacción real:** conversaciones históricas de producción, usadas como línea base para evaluar el rediseño.

5. Componente de innovación / investigación aplicada

La innovación central es la interoperabilidad de agentes bajo protocolos abiertos (MCP y A2A): migrar un sistema real hacia un ecosistema de agentes especializados que se descubren, delegan tareas y colaboran sin acoplamiento fuerte. El equipo ya resolvió en producción desafíos de ingeniería no triviales (timeouts en webhooks, bucles de retroalimentación, duplicación de eventos, autenticación segura de credenciales), lo que da una base técnica sólida para evaluar honestamente qué se gana y qué fricciones introduce MCP/A2A en un caso real, con datos reales.

MCP (Model Context Protocol) estandariza cómo un agente se conecta a herramientas y datos externos: en vez de código de integración a medida por cada API o base de datos, la capacidad se expone con un esquema común que cualquier agente compatible puede descubrir y usar. A2A (Agent-to-Agent) estandariza, la comunicación entre agentes autónomos entre sí: cada agente publica qué sabe hacer y otros pueden descubrirlo y delegarle tareas, incluso si fueron construidos con frameworks o proveedores distintos. Concretamente, la innovación reemplaza la integración hoy cableada a mano en el nodo único de n8n por ambos estándares: el orquestador delegará vía A2A a los agentes pares (Disponibilidad, Conocimiento, Recomendador), y cada uno expondrá sus capacidades vía MCP, reutilizables por cualquier cliente compatible y no solo por este flujo.

Integrante del Equipo:

- Elkin David Ortiz Rodriguez CC. 1.143.346.593